# Введение в параллельные вычисления

## Лекция 7. MPI (часть 1)

КС-40, КС-44
РХТУ

Преподаватель
Митричев Иван Игоревич, к.т.н.,
ассистент кафедры ИКТ

2017

# MPI

Message passing interface -

с англ., дословно - интерфейс передачи сообщений.

# Выбор модели программирования

Системы с общей памятью

- C++11 threads (pthreads)
- OpenMP

Системы с распределенной памятью

- MPI = message passing interface

Гетерогенные системы (графические процессоры)

- CUDA

# Некоторые ссылки

Стандарты MPI http://www.mpi-forum.org спецификация MPI-1.1

Обмен данными с использованием MPI.

- http://habrahabr.ru/company/intel/blog/251357/

Лекции и семинары

- http://www.slideshare.net/Aleximos/mpi-9793227

Технологии

- http://parallel.ru/tech/tech_dev/mpi.html
- http://parallel.ru/tech/tech_dev/MPI/examples/ (примеры)

Примеры из учебника "Технологии параллельного программирования MPI и OpenMP"

- http://parallel.ru/tech/tech_dev/MPI%26OpenMP/examples/

# Литература


•Богачёв К.Ю. Основы параллельного программирования. М.: БИНОМ. Лаборатория знаний, 2003.

•Немнюгин С.А. Средства программирования для многопроцессорных вычислительных систем. Спб., 2007.

•Антонов А.С. Параллельное программирование с использованием технологии MPI. М.: Изд-во МГУ, 2004.

•Шпаковский Г.И. , Серикова Н.В. Программирование для многопроцессорных систем в стандарте MPI. Мн.: БГУ, 2002.


# Учебные материалы по MPI, доступные в Internet

•Лекция об MPI в курсе "Параллельная обработка данных" (Вл.В.Воеводин).

•Вычислительный практикум по технологии MPI (А.С.Антонов).

•Глава об MPI(link is external) в книге Яна Фостера "Designing and Building Parallel Programs".

•Учебные материалы по MPI(link is external) на сервере МНРСС.

•MPI: The Complete Reference(link is external). Авторы: Marc Snir, Steve Otto, Steve Huss-Lederman, David Walker, Jack Dongarra(link is external).

•Tutorial on MPI: The Message Passing Interface(link is external). Автор: Bill Gropp(link is external).

•Writing Message-Passing Parallel Programs with MPI(link is external) – учебный курс по MPI, созданный в EPCC (The University of Edinburgh). Авторы: Neil MacDonald, Elspeth Minty, Mario Antonioletti, Joel Malard, Tim Harding, Simon Brown.

# Message Passing Interface


**Message Passing Interface** (MPI, интерфейс передачи сообщений) – программный интерфейс (API) для передачи информации, который позволяет обмениваться сообщениями между процессами, выполняющими одну задачу.

MPI – наиболее распространённый стандарт интерфейса обмена данными в параллельном программировании, существуют его реализации для большого числа компьютерных платформ. В настоящее время существует большое количество бесплатных и коммерческих реализаций MPI. Существуют реализации для языков Фортран 77/90, Java, Си и Си++.

MPI ориентирован на системы с распределенной памятью, при этом часто затраты на передачу данных велики (бутылочное горлышко).

**Технологии OpenMP и MPI могут использоваться совместно, чтобы оптимально использовать многоядерные системы.**

# Стандарты MPI

Первая версия MPI разрабатывалась в 1993 – 1994 году, и MPI 1 вышла в 1994.

Большинство современных реализаций MPI поддерживают версию 1.1. Стандарт MPI версии 2.0 поддерживается большинством современных реализаций, однако некоторые функции могут быть реализованы не до конца. MPI 3.1 (2015) – последняя версия стандарта.


## Примеры реализаций MPI

- MPICH – самая распространённая свободная реализация, работает на UNIX-системах и Windows NT
- Intel MPI – коммерческая реализация для Windows / Linux
- Oracle HPC ClusterTools – бесплатная реализация для Solaris SPARC/x86 и Linux на основе Open MPI
- MPJ – MPI for Java
- MPJ Express – MPI на Java и др.

# MPI-2

Сегодня и на следующей лекции мы изучаем MPI-1.

MPI-2 содержит 4 коренных отличия от MPI-1:

1) Функции для удаленного изменения памяти, а не обмена (MPI_Put, MPI_Get, MPI_Accumulate)
2) Динамическое управление процессами (MPI_Comm_spawn, MPI_Comm_accept / MPI_Comm_connect, MPI_Comm_join)
3) Параллельный ввод-вывод
4) Расширение коллективных функций на несколько коммуникаторов

# Функционирование интерфейса

Базовым механизмом связи между MPI процессами является передача и приём сообщений.

Сообщение несёт передаваемые данные и информацию, позволяющую принимающей стороне осуществлять их выборочный приём:

- отправитель – ранг (номер в группе) отправителя сообщения;
- получатель – ранг получателя;
- Признак (attribute) – может использоваться для разделения различных видов сообщений;
- коммуникатор – код группы процессов.

Операции приёма и передачи могут быть блокирующимися и неблокирующимися. Для неблокирующихся операций определены функции проверки готовности и ожидания выполнения.
Другим способом связи является удалённый доступ к памяти (RMA), позволяющий читать и изменять область памяти удалённого процесса. Локальный процесс может переносить область памяти удалённого процесса (внутри указанного процессами окна) в свою память и обратно, а также комбинировать данные, передаваемые в удалённый процесс с имеющимися в его памяти данными (например, путём суммирования). Все операции удалённого доступа к памяти не блокирующиеся, однако, до и после их выполнения необходимо вызывать блокирующиеся функции синхронизации.

Полная версия интерфейса содержит описание более 125 процедур и функций.

# Модель передачи сообщений

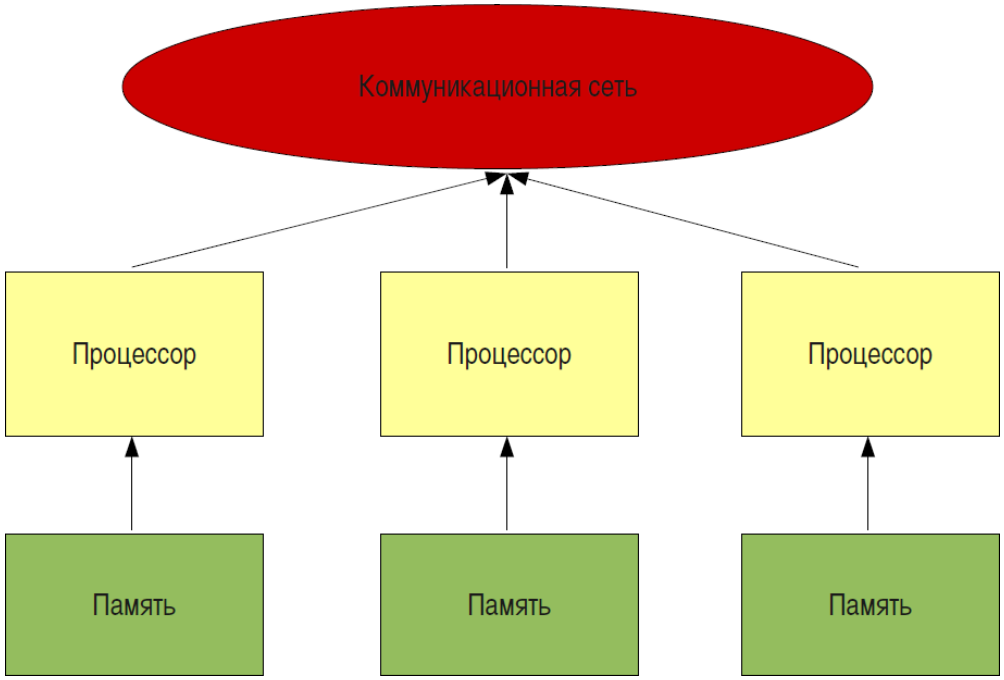


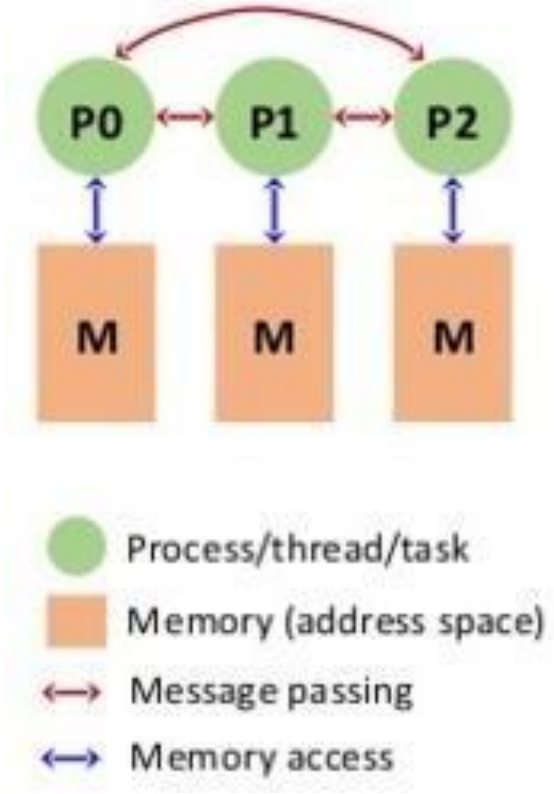


Программа состоит из N параллельных процессов, которые порождаются при запуске (MPI-1) или м.б. динамически созданы во время выполнения (MPI-2).

# Передача сообщения – способ взаимодействия

**Каждый процесс имеет уникальный идентификатор** и изолированное адресное пространство.

**Общих переменных или данных в MPI нет.**

Процессы могут образовывать группы для реализации коллективных операций обмена информацией.

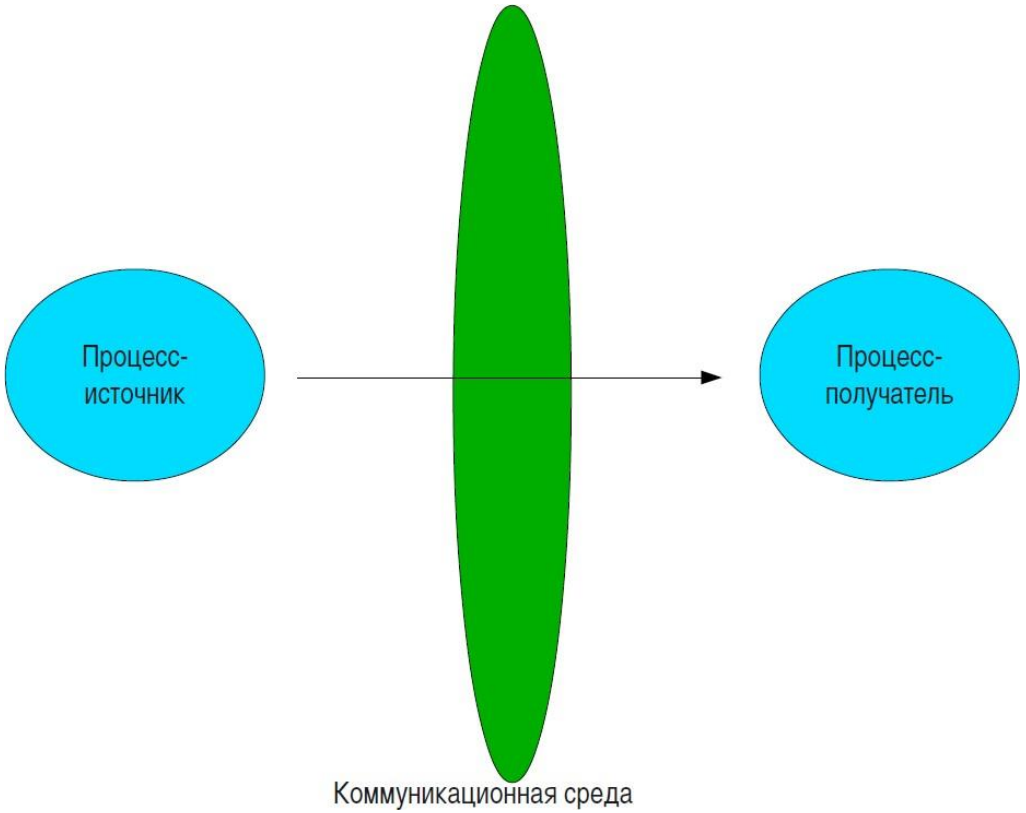

# Терминология и обозначения

*MPI* – библиотека функций, предназначенная для поддержки работы параллельных процессов в терминах передачи сообщений.

*Номер процесса* – целое неотрицательное число, являющееся уникальным атрибутом каждого процесса.

*Атрибуты сообщения* – номер процесса-отправителя, номер процесса-получателя и идентификатор сообщения.

Заведена структура *MPI_Status*, содержащая поля:

- *MPI_Source* (номер процесса отправителя),
- *MPI_Tag* (идентификатор сообщения),
- *MPI_Error* (код ошибки); могут быть и добавочные поля.

*Идентификатор сообщения (msgtag)* – атрибут сообщения, являющийся целым неотрицательным числом, лежащим в диапазоне от 0 до 32767.
Процессы объединяются в *группы*, внутри группы все процессы перенумерованы.
С каждой группой ассоциирован свой *коммуникатор*.
Процесс имеет два основных атрибута – *коммуникатор и номер в коммуникаторе*.

# Коммуникатор и ранги

Коммуникатор (communicator) – множество процессов, образующих логическую область для выполнения коллективных операций (обменов информацией и др.)

Состав групп произволен. Группы могут совпадать, входить одна в другую, не пересекаться или пересекаться частично. Процессы могут взаимодействовать только внутри некоторого коммуникатора, сообщения в разных коммуникаторах не пересекаются.

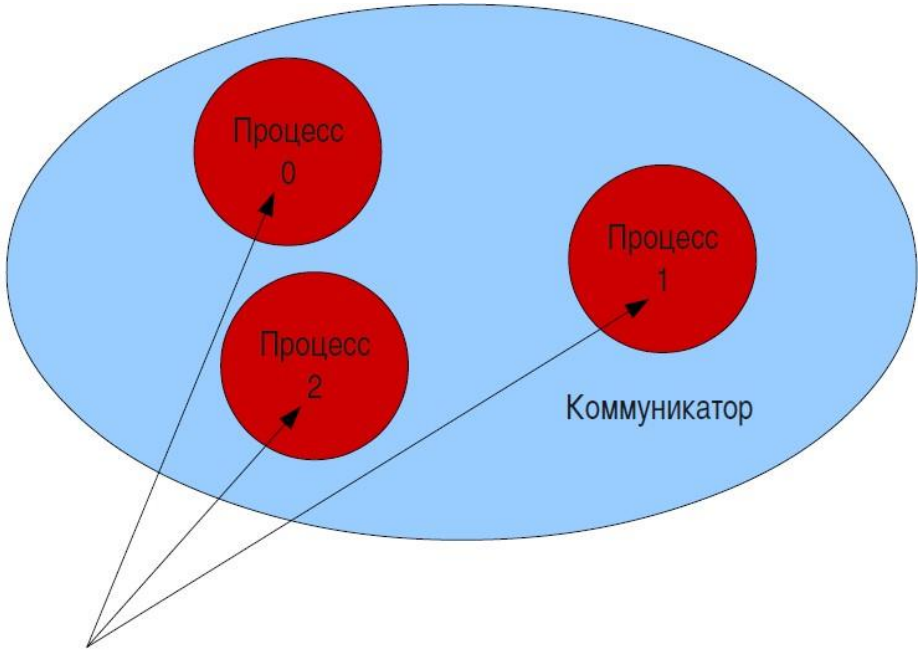


Ранги процессов

Каждый процесс имеет специальный идентификатор – ранг (rank).
Каждый процесс в рамках одного коммуникатора имеет уникальный ранг.

# Локализация и коммуникаторы

Коммуникатор – среда общения.

Коммуникаторы имеют предопределенный тип – MPI_Comm.

При старте программы все порожденные процессы работают в рамках коммуникатора MPI_COMM_WORLD.

Он существует всегда и служит для взаимодействия всех запущенных процессов MPI-программы.

При старте программы имеется коммуникатор MPI_COMM_SELF, содержащий только один текущий процесс, и коммуникатор MPI_COMM_NULL, не содержащий ни одного процесса.

При пересылке необходимо указать идентификатор группы, внутри которой производится эта пересылка. Все процессы содержатся в группе с предопределенным идентификатором MPI_COMM_WORLD.

# Установка MPI

Одна из самых распространённых реализаций MPI – MPICH (MPI Chameleon).

Установка в Ubuntu: sudo apt-get install mpich2
Компиляция: mpic++ -o test ./test.cpp
Запуск: mpirun -np 4 test

Официальный сайт: http://www.mpich.org/
Скачайть библиотеку MPICH2:
wget http://www.mpich.org/static/downloads/3.0.4/mpich-3.0.4.tar.gz
Распаковать tar-архив: tar xzvf mpich-3.0.4.tar.gz

# Общий вид MPI программы

Параллельная программа с точки зрения MPI – набор процессов, запущенных на разных вычислительных узлах. Каждый процесс порождается на основе одного и того же программного кода.

```
mpicc -o hello program0.c
mpiexec -n 5 hello
```

```
#include "mpi.h"
#include <stdio.h>

int main(int argc, char *argv[])
{
    int myid, numprocs;
    MPI_Init(&argc, &argv);
    MPI_Comm_size(MPI_COMM_WORLD,&numprocs);
    MPI_Comm_rank(MPI_COMM_WORLD, &myid);
    fprintf(stdout,"Process %d of %d\n",myid,numprocs);
    MPI_Finalize();
    return 0;
}
```

# Общие процедуры MPI

Общие процедуры необходимы в каждой параллельной программе
int MPI_Init( int* argc, char*** argv)

MPI_Init – инициализация параллельной части (реальная инициализация для каждого приложения происходит не более одного раза, если повторно, то действия не выполняются и происходит возврат из подпрограммы).

Все MPI-процедуры могут быть вызваны только после вызова MPI_Init.

Процедура возвращает: в случае успешного выполнения – MPI_SUCCESS, иначе – код ошибки.

int MPI_Finalize( void )

MPI_Finalize – завершение параллельной части приложения.
К моменту вызова MPI_Finalize некоторым процессом все действия, требующие его участия в обмене сообщениями, должны быть завершены. Сложный тип аргументов *MPI_Init* предусмотрен, чтобы передавать всем процессам аргументы *main*:

```
int main(int argc, char** argv)
{
        MPI_Init(&argc, &argv);
                ...
        MPI_Finalize();
}
```

# Общие процедуры MPI

**int MPI_Comm_size( MPI_Comm comm, int* size)**

Определение общего числа параллельных процессов в группе *comm*.

*comm* – идентификатор группы; OUT *size* – размер группы.

**int MPI_Comm_rank( MPI_Comm comm, int* rank)**

Определение номера процесса в группе *comm*.

Значение, возвращаемое по адресу *&rank*, лежит в диапазоне от 0 до *size_of_group-1*.

*comm* – идентификатор группы;

OUT *rank* – номер вызывающего процесса в группе *comm.*

**double MPI_Wtime(void)**

Функция возвращает астрономическое время в секундах (вещественное число), прошедшее с некоторого момента в прошлом.

Гарантируется, что этот момент не будет изменен за время существования процесса.

# Пример

Каждый запущенный процесс печатает свой уникальный номер в коммуникаторе MPI_COMM_WORLD и число процессов в данном коммуникаторе.

Строка вывода выведена столько раз, сколько процессов порождено при запуске.

Порядок строк не определен.

(см. код Си)

```c
#include "mpi.h"
#include <stdio.h>
#include <iostream>
using namespace std;
int main(int argc, char *argv[])
{
int myid, numprocs;
    MPI_Init(&argc, &argv);
    MPI_Comm_size(MPI_COMM_WORLD,&numprocs);
    MPI_Comm_rank(MPI_COMM_WORLD, &myid);
    cout << "    Process " << myid << " of " << numprocs << endl;
    MPI_Finalize();
return 0;
}
```

```
$ mpirun -np 5 ./hello
```

```
Process 3 of 5
Process 2 of 5
Process 4 of 5
Process 0 of 5
Process 1 of 5
```

# Пример PROSSESSOR_NAME

```
#define NTIMES 100
int main(int argc, char **argv)
{
  double time_start, time_finish, tick;  int rank, i; int len;
  char *name;
  name = (char*)malloc(MPI_MAX_PROCESSOR_NAME*sizeof(char));
  MPI_Init(&argc, &argv);
  MPI_Comm_rank(MPI_COMM_WORLD, &rank);
  MPI_Get_processor_name(name, &len);
  tick = MPI_Wtick();  time_start =
  MPI_Wtime();  for (i = 0; i<NTIMES; i++)
    time_finish = MPI_Wtime();
  cout << " processor " << name << " process " << rank << " tick = ";  cout << tick << " time
  = " << (time_finish-time_start)/NTIMES << endl;  MPI_Finalize();
}
```

MPI_Wtick() – разрешение таймера на вызвавшем процессоре в сек.

MPI_Get_processor_name (name, &len) – name – имя узла, на котором запущен вызвавший процесс; len – количество символов в имени.

# Передача/прием сообщений

Основная операция в MPI – передача сообщений.
В MPI реализованы практически все основные коммуникационные шаблоны: двухточечные (point-to-point), коллективные (collective) и односторонние (one-sided).

Программы содержат средства порождения и завершения параллельных процессов и средства взаимодействия запущенных процессов между собой.

Процедуры передачи:

Индивидуальные типа точка-точка.

Коллективные – в операцию вовлечены все процессоры коммуникатора.

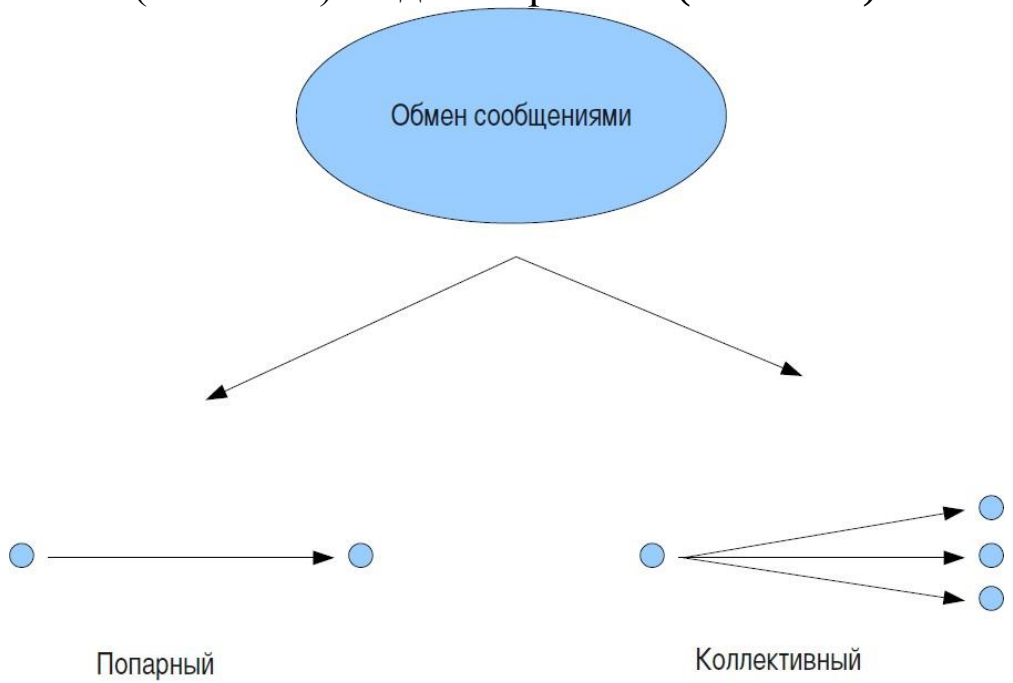

# Обмен сообщениями

Все процедуры делятся на классы: процедуры с блокировкой (с синхронизацией) и без блокировки (асинхронные).

Процедуры обмена с блокировкой приостанавливают работу до выполнения условия. Возврат из асинхронных происходит немедленно после инициализации коммуникационной операции.

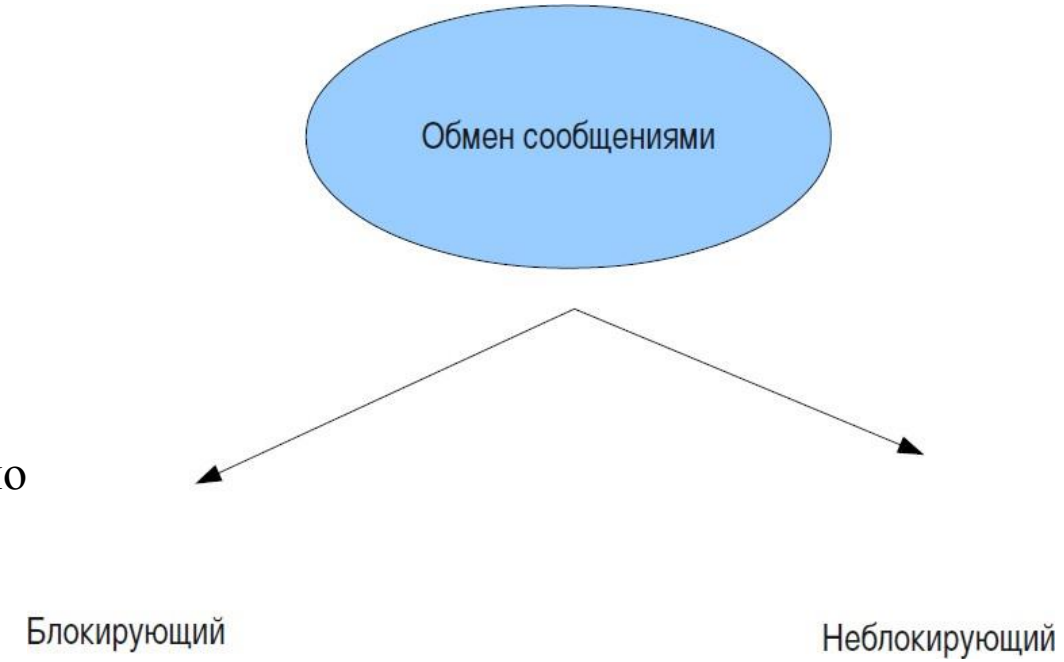


Неаккуратность с блокировкой приводит к тупиковым ситуациям.

Использование асинхронных операций требует аккуратного использования массивов данных.

# Составляющие сообщения

1. Блок данных сообщения – void *
2. Информация о данных сообщения.
   (a) Тип данных – MPI_Datatype;
   (b) Количество данных.
3. Информация о получателе и отправителе сообщения.
   (a) Коммуникатор – идентификатор группы процессов типа MPI_Comm, коммуникатор верхнего уровня – MPI_COMM_WORLD;
   (b)Ранг получателя – номер процесса получателя в указанном коммуникаторе;
   (c)Ранг отправителя – номер процесса отправителя в указанном коммуникаторе Можно принимать сообщения от всех отправителей в данном коммуникаторе MPI_ANY_SOURCE.
4. Тег сообщения.
   Произвольное число типа int. Можно принимать сообщения с определенным тегом, можно с любым – MPI_ANY_TAG.

# Соответствие типов данных MPI и C

| Тип MPI | Тип C |
|---|---|
| MPI_CHAR | signed char |
| MPI_SHORT | signed short int |
| MPI_INT | signed int |
| MPI_LONG | signed long int |
| MPI_UNSIGNED_CHAR | unsigned char |
| MPI_UNSIGNED_SHORT | unsigned short int |
| MPI_UNSIGNED_INT | unsigned int |
| MPI_UNSIGNED_LONG | unsigned long int |
| MPI_FLOAT | float |
| MPI_DOUBLE | double |
| MPI_LONG_DOUBLE | long double |
| MPI_BYTE | unsigned char |
| MPI_PACKED | |

Богачёв К. Ю.

Основы параллельного программирования / К. Ю. Богачёв. — М.: БИНОМ. Лаборатория знаний, 2003. — 342 с., илл.

# Общие процедуры и коммуникаторы

```
int MPI_Comm_size (MPI_Comm comm, int *size);
```

получить количество процессов в коммуникаторе

коммуникатор

указатель на результат

```
int p;
MPI_Comm_size(MPI_COMM_WORLD, &p);
```

получить количество всех процессов

```
Int MPI_Comm_rank(MPI_Comm comm,int *rank);
```

получить ранг (номер) процесса в группе (коммуникаторе)

```
int my_rank;
Int MPI_Comm_rank(MPI_COMM_WORLD, &my_rank);
```

в глобальном коммуникаторе

# Режимы коммуникации (обмена сообщениями)

Определяют, когда завершается (а также, и когда начинается) прием и отправка сообщений.

Отправка сообщения

1. Стандартный (standard) – сообщения могут буферизироваться или нет в зависимости от наличия свободного места в буфере, могут не буферизироваться с целью оптимизации производительности. Является нелокальным, то есть использует информацию о наличии ожидающих запросов на получение сообщения (receive). Без префикса
2. Буферизованный (buffered) – сообщения обязательно буферизуются. Является локальным, то есть вызов завершается независимо от того, есть ли ожидающие запросы на получение сообщения (receive). Префикс R у функций (MPI_RSEND)
3. Синхронный (synchronous) – отправка завершается только тогда, когда есть соответствующий запрос на получение. Префикс S (MPI_SSEND)
4. По готовности (ready) – отправка сообщения может быть начата только, когда есть соответствующий запрос на получение. Префикс R (MPI_RSEND)

Прием сообщения – один режим. Когда сообщение поступает в буфер, прием завершается

# Блокирующая посылка сообщения

Операции точка-точка с синхронизацией (один – отправитель, другой – получатель)

**int MPI_Send(void* buf, int count, MPI_Datatype datatype, int dest, int msgtag, MPI_Comm comm)**

*buf* – адрес начала буфера посылки сообщения;
*count* – число передаваемых элементов в сообщении;
*datatype* – тип передаваемых элементов;
*dest* – номер процесса-получателя;
*msgtag* – идентификатор сообщения;
*comm* – идентификатор группы.

Блокирующая посылка сообщения с идентификатором *msgtag*, состоящего из *count* элементов типа *datatype*, процессу с номером *dest*. Все элементы сообщения расположены подряд в буфере *buf*. Значение *count* может быть нулем. Тип передаваемых элементов *datatype* должен указываться с помощью предопределенных констант типа **MPI_Datatype**. Разрешается передавать сообщение самому себе, что может привести к тупиковым ситуациям.

# Блокирующая посылка сообщения

Блокировка гарантирует корректность повторного использования всех параметров после возврата из подпрограммы посредством копирования в промежуточный буфер или непосредственной передачи процессу *dest*.

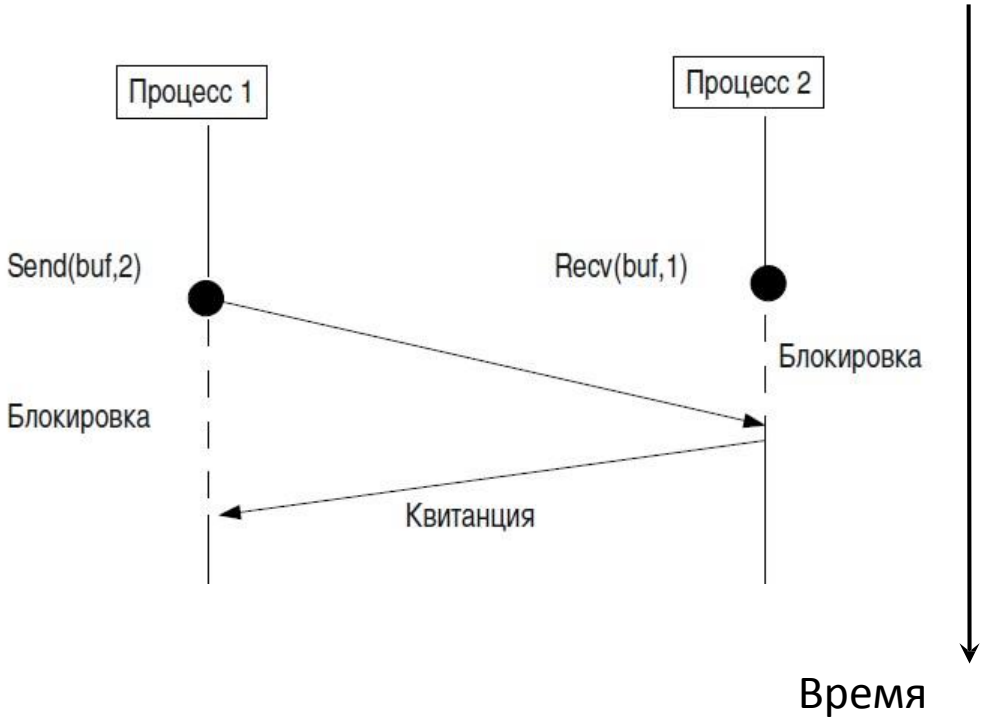

# Прием сообщения

**int MPI_Recv(void* buf, int count, MPI_Datatype datatype, int source, int msgtag, MPI_Comm comm, MPI_Status *status)**

OUT *buf* – адрес начала буфера приема сообщения;
*count* – максимальное число элементов в принимаемом сообщении;
*datatype* – тип элементов принимаемого сообщения;
*source* – номер процесса-отправителя;
*msgtag* – идентификатор принимаемого сообщения;
OUT *status* – параметры принятого сообщения.

Прием сообщения с идентификатором *msgtag* от процесса *source* с блокировкой. Число элементов в принимаемом сообщении не должно превосходить значения *count*. Если число принятых элементов меньше значения *count*, то гарантируется, что в буфере *buf* изменятся только элементы, соответствующие элементам принятого сообщения. Чтобы узнать точное число элементов в сообщении – функция *MPI_Probe*.

Блокировка гарантирует, что после возврата из подпрограммы все элементы сообщения приняты и расположены в буфере *buf*.

Если процесс посылает два сообщения другому процессу и оба эти сообщения соответствуют одному и тому же вызову *MPI_Recv*, то первым будет принято то сообщение, которое было отправлено раньше.

# Обмен сообщениями для двух процессов

Нулевой процесс посылает сообщение процессу с номером 1 и ждет от него ответа.

Программа запущена на 3-х процессах, выполняют пересылки 0 и 1.

```
process 2 a = 0 b = 0
process 0 a = 2 b = 1
process 1 a = 2 b = 1
```

```
#include "mpi.h"
#include <stdio.h>
int main(int argc, char **argv) {
  int rank;  float a, b;        MPI_Status status;
  MPI_Init(&argc, &argv);
  MPI_Comm_rank(MPI_COMM_WORLD, &rank);
  a = 0.0;              b = 0.0;
  if ( rank == 0 ) {
    b = 1.0;
    MPI_Send(&b, 1, MPI_INT, 1, 5, MPI_COMM_WORLD);
    MPI_Recv(&a, 1, MPI_INT, 1, 5, MPI_COMM_WORLD, &status);
  }
  if ( rank == 1 ) {
    a = 2.0;
    MPI_Recv(&b, 1, MPI_FLOAT, 0, 5, MPI_COMM_WORLD, &status);
    MPI_Send(&a, 1, MPI_FLOAT, 0, 5, MPI_COMM_WORLD);
  }
  cout << " process " << rank << " a = " << a << " b = " << b << endl;
  MPI_Finalize();
}
```

# Пример MPI_Send/MPI_Recv

Каждый процесс с четным номером посылает сообщение соседу с номером на 1 большим.

Поставлена проверка для процесса с максимальным номером он не посылает сообщение несуществующему процессу.

Значение *b* изменяется только на процессах с нечетными номерами.

```
process 1 a = 1 b = 0
process 0 a = 0 b = -1
process 2 a = 2 b = -1
```

```
#include "mpi.h"
#include <stdio.h>
int main(int argc, char **argv) {
  int size, rank, a, b;
  MPI_Status status;
  MPI_Init(&argc, &argv);
  MPI_Comm_size(MPI_COMM_WORLD, &size);
  MPI_Comm_rank(MPI_COMM_WORLD, &rank);
  a = rank;          b = – 1;
  if (( rank%2 )  == 0) {
    if ( rank < size – 1 )
      MPI_Send(&a, 1, MPI_INT, rank+1, 5, MPI_COMM_WORLD);
  }
  else
    MPI_Recv(&b, 1, MPI_INT, rank-1, 5, MPI_COMM_WORLD, &status);
  cout << " process " << rank <<  " a = " << a << " b = " << b << endl;
  MPI_Finalize();
}
```

# Выборочный прием сообщения

При приеме сообщений вместо аргументов SOURCE и MSGTAG можно использовать предопределенные константы:

- MPI_ANY_SOURCE – признак, что подходит сообщение от любого процесса;
- MPI_ANY_TAG – признак, что подходит сообщение с любым идентификатором.

При одновременном использовании будет принято сообщение с любым идентификатором от любого процесса.

## О статусе сообщения

Атрибуты принятого сообщения можно определить по элементам массива status.

Параметр status – **структура** предопределенного типа MPI_Status с полями MPI_SOURCE (реальный ранг сообщения), MPI_TAG (реальный тег) и MPI_ERROR (код ошибки).

Номер принимающего процесса требуется указать явно.

Если один процесс посылает два сообщения, соответствующие одному MPI_Recv, другому процессу, то первым принимается первое сообщение.

Если сообщение отправлено разными процессами, то порядок получения не определен.

# Неблокирующий обмен сообщениями

Асинхронная передача данных.

Возврат сразу после вызова без остановки работы процессов.

Для завершения асинхронного обмена требуются дополнительные процедуры, с целью использования буфера.

До завершения неблокирующей операции нельзя записывать в используемый массив данных.

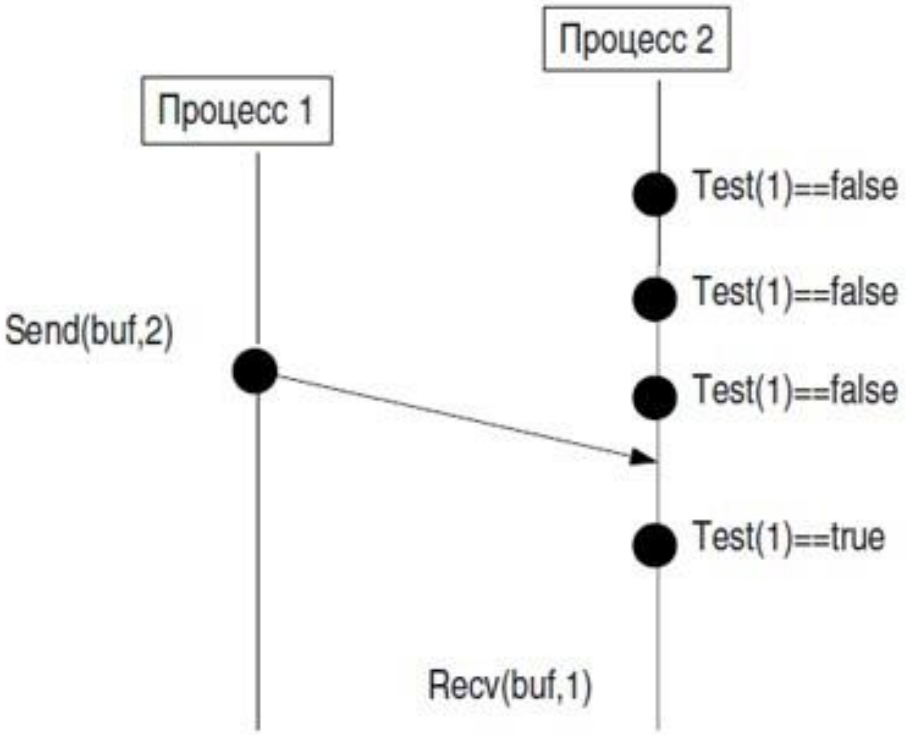

# Прием/передача сообщений без блокировки

**int MPI_Isend(void *buf, int count, MPI_Datatype datatype, int dest, int msgtag,**
**MPI_Comm comm, MPI_Request *request)**

OUT *request* – идентификатор асинхронной передачи

Передача аналогична *MPI_Send*, но возврат из подпрограммы сразу после инициализации процесса передачи без ожидания обработки всего сообщения, находящегося в буфере *buf*. Нельзя повторно использовать буфер без получения дополнительной информации о завершении данной посылки.
Сообщение, отправленное любой из процедур *MPI_Send* и *MPI_Isend*, может быть принято любой из процедур *MPI_Recv* и *MPI_Irecv*.
Предусмотрены три дополнительных варианта, подобные модификациям процедуры *MPI_Send*.

**int MPI_Irecv(void *buf, int count, MPI_Datatype datatype, int source, int msgtag,**
**MPI_Comm comm, MPI_Request *request)**

OUT *request* – идентификатор асинхронного приема сообщения

Прием сообщения аналогичный *MPI_Recv*, однако возврат из подпрограммы происходит сразу после инициализации процесса приема без ожидания получения сообщения в буфере *buf*.
Окончание процесса приема можно определить с помощью параметра *request* и процедур *MPI_Wait* и *MPI_Test*.

***Отличие в параметрах от блокирующего обмена: Request вместо Status.***

# Завершение асинхронного обмена

**int MPI_Wait( MPI_Request *request, MPI_Status *status)**

*request* – идентификатор асинхронного приема или передачи;

OUT *status* – параметры сообщения.

Ожидание завершения асинхронных процедур *MPI_Isend* или *MPI_Irecv*, ассоциированных с идентификатором *request*. В случае приема, атрибуты и длину полученного сообщения можно определить с помощью параметра *status*.

**int MPI_Waitall( int count, MPI_Request *requests, MPI_Status *statuses)**

*requests* – массив идентификаторов асинхронного приема или передачи;

OUT *statuses* – параметры сообщений.

Выполнение процесса блокируется до тех пор, пока все операции обмена, ассоциированные с указанными идентификаторами, не будут завершены. Если во время одной или нескольких операций обмена возникли ошибки, то поле ошибки в элементах массива *statuses* будет установлено в соответствующее значение.

# Неблокирующий обмен - пример

```
#include "mpi.h"
#include <stdio.h>

int main(int argc, char **argv)
{
   int rank, size, prev, next;
   int buf[1];
MPI_Request reqs[2];
MPI_Status stats[2];
MPI_Init(&argc,&argv);
MPI_Comm_size(MPI_COMM_WORLD, &size);
MPI_Comm_rank(MPI_COMM_WORLD, &rank);
MPI_Irecv(&buf[0], 1, MPI_INT, prev, 5, MPI_COMM_WORLD, &reqs[0]);
MPI_Isend(&rank, 1, MPI_INT, next, 5, MPI_COMM_WORLD, &reqs[1]);
MPI_Waitall(2, reqs, stats);
cout << " process " << rank << buf[0] << endl;
MPI_Finalize();              }
```

top50.supercomputers.ru/?page=rating

# Top50

| N | Место | Кол-во CPU/ядер | Архитектура (тип процессора / сеть ) | Производительность (Tflop/s) Linpack | Производительность (Tflop/s) Пиковая | Разработчик |
|---|---|---|---|---|---|---|
| 1 | Москва<br>Московский государственный университет имени М.В.Ломоносова<br>2016 г. | 1472/42688 | узлов: 1472 (Xeon E5-2697v3 [Acc: Tesla K40M] 2.6 GHz 64 GB RAM)<br>сеть: Infiniband FDR/Infiniband FDR/Gigabit Ethernet | 2,102.00 | 2,962.30 | Т-Платформы |
| 2 | Москва<br>Московский государственный университет имени М.В.Ломоносова<br>2012 г. | 12422/82468 | узлов: 4160 (2xXeon 5570 2.93 GHz 12 GB RAM)<br>узлов: 777 (2xXeon E5630 [Acc: 2xTesla X2070] 2.53 GHz 12 GB RAM)<br>узлов: 640 (2xXeon 5670 2.93 GHz 24 GB RAM)<br>узлов: 288 (2xXeon E5630 [Acc: 2xTesla X2070] 2.53 GHz 24 GB RAM)<br>узлов: 260 (2xXeon 5570 2.93 GHz 24 GB RAM)<br>узлов: 40 (2xXeon 5670 2.93 GHz 48 GB RAM)<br>узлов: 30 (2xPowerXCell 8i 3.2 GHz 16 GB RAM)<br>узлов: 4 (4xXeon E7650 2.26 GHz 512 GB RAM)<br>сеть: Infiniband QDR/Gigabit Ethernet/Gigabit Ethernet | 901.90 | 1,700.21 | Т-Платформы |
| 3 | Санкт-Петербург<br>Суперкомпьютерный центр Санкт-Петербургский политехнический университет<br>2017 г. | 1468/20552 | узлов: 623 (2xXeon E5-2697v3 2.6 GHz 64 GB RAM)<br>узлов: 56 (2xXeon E5-2697v3 [Acc: 2x NVIDIA K40] 2.6 GHz 64 GB RAM)<br>узлов: 36 (2xXeon E5-2697v3 2.6 GHz 128 GB RAM)<br>узлов: 8 (2xXeon E5-2697v3 [Acc: NVIDIA K1] 2.6 GHz 128 GB RAM)<br>узлов: 8 (2xXeon E5-2697v3 [Acc: NVIDIA K2] 2.6 GHz 128 GB RAM)<br>узлов: 3 (2xXeon E5-2697v3 2.6 GHz 256 GB RAM)<br>сеть: Infiniband FDR/Gigabit Ethernet/Gigabit Ethernet | 715.94 | 1,015.10 | Группа компаний РСК |
| 4 | Москва<br>МСЦ РАН<br>2016 г. | 416/28704 | узлов: 208 (2xXeon E5-2690 [Acc: 2x Xeon Phi 7110X] 2.9 GHz 80 GB RAM)<br>сеть: Infiniband FDR/Gigabit Ethernet/Fast Ethernet | 383.21 | 523.83 | Группа компаний РСК |
| 5 | Москва<br>Суперкомпьютерный вычислительный комплекс НИЦ "Курчатовский институт"<br>2015 г. | 296/10064 | узлов: 148 (2xXeon E5-2650v2 [Acc: 2x Tesla K80] 2.6 GHz 128 GB RAM)<br>сеть: Infiniband FDR/Gigabit Ethernet/Gigabit Ethernet | 381.40 | 601.00 | Т-Платформы |
| 6 | Москва<br>Центр обработки данных НИЦ "Курчатовский институт"<br>2015 г. | 774/11082 | узлов: 364 (2xXeon E5-2680v3 2.5 GHz 128 GB RAM)<br>узлов: 23 (2xXeon E5-2680v3 [Acc: 3x NVidia K80] 2.5 GHz 128 GB RAM)<br>сеть: Infiniband FDR/Gigabit Ethernet/Gigabit Ethernet | 374.13 | 500.55 | SuperMicro, Борлас |